John Dark Soul

Agente sobre el lore
de **Dark Souls I, II y III**
construido con **LangChain** y **LangGraph**

Santiago Cardozo
Santiago Toro

El Problema

El lore de Dark Souls está disperso
en objetos y diálogos.

Un LLM responde con seguridad aunque
se equivoque.

Necesitamos un agente que responda
solo con fuentes verificables
las cite y declare cuando no sabe

ARQUITECTURA

Aplicación web con agente **RAG** y base vectorial

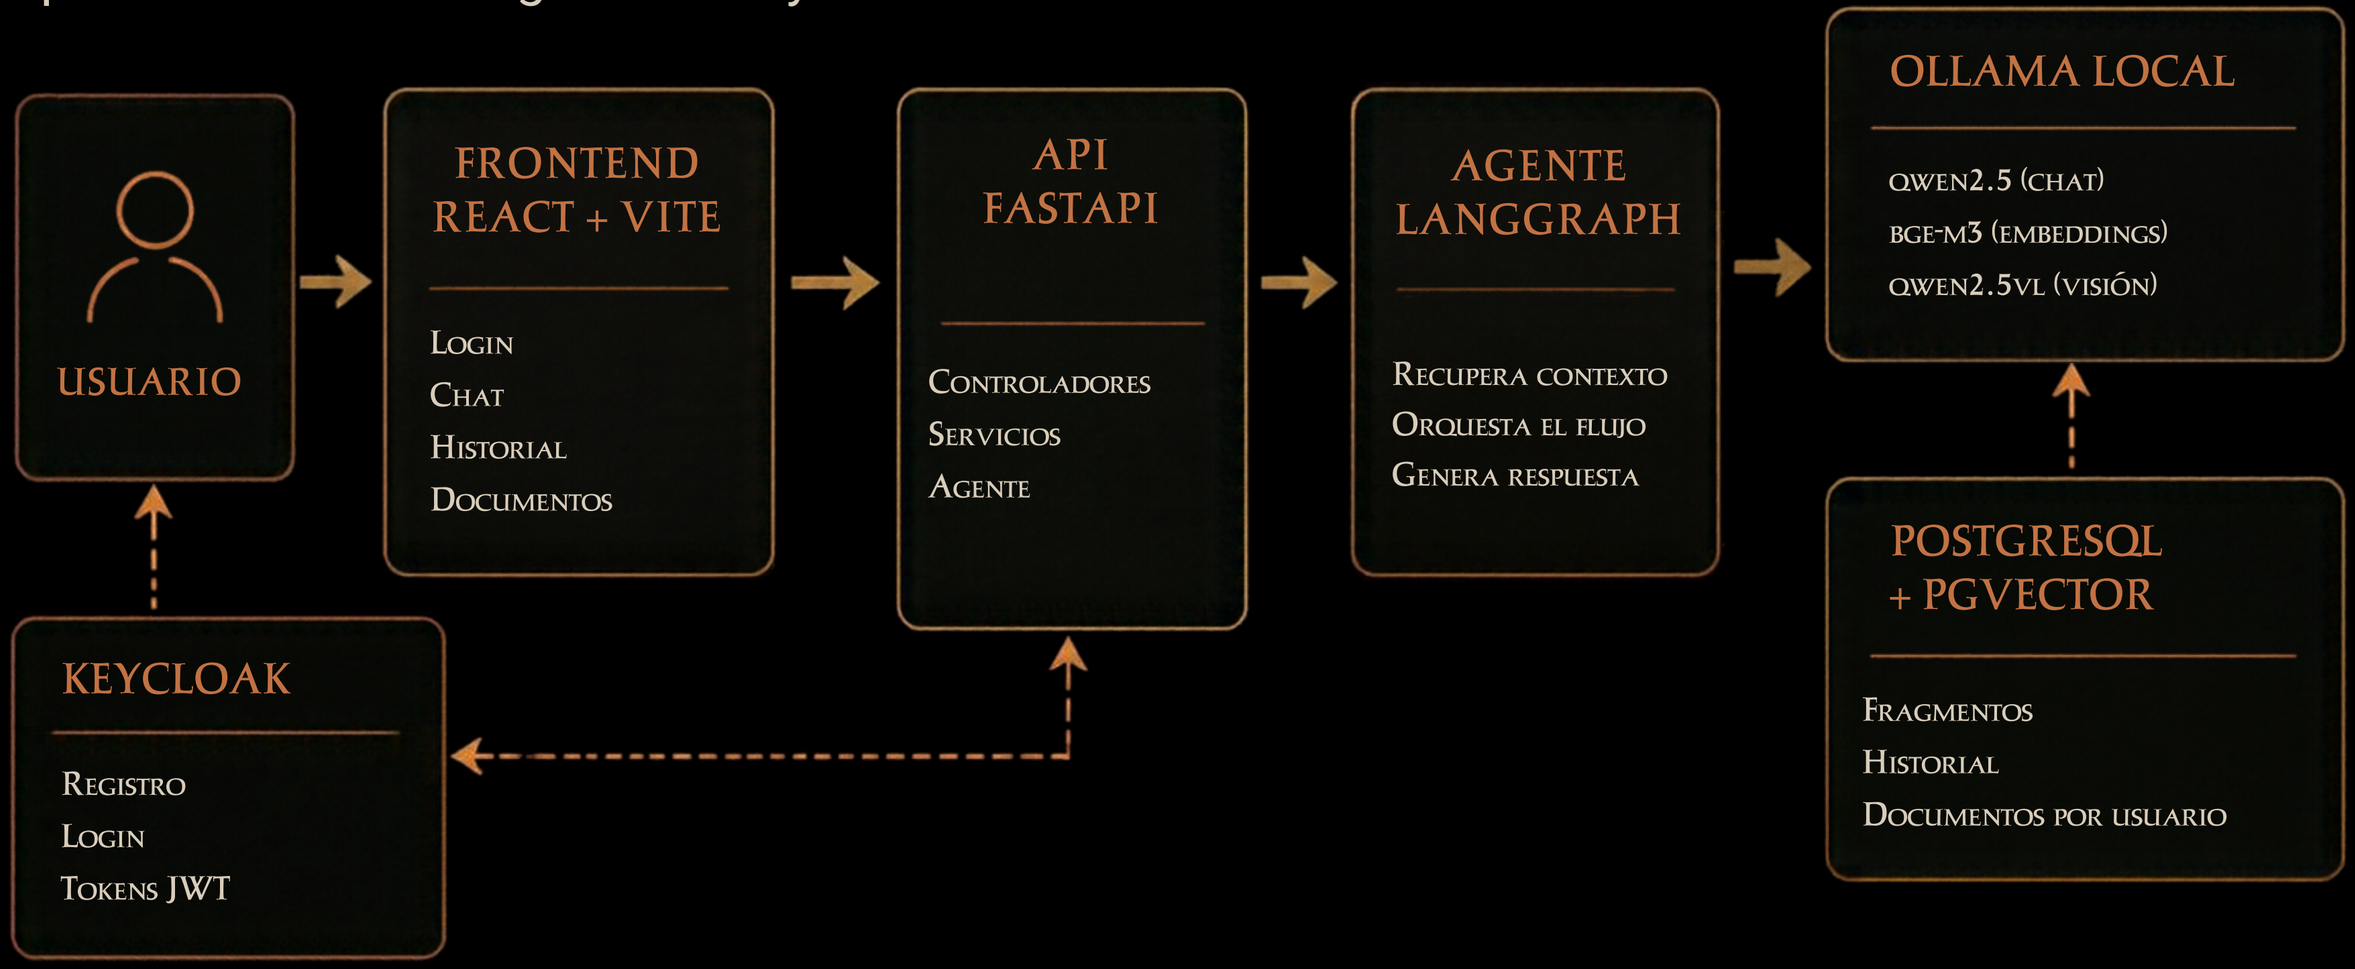

Tecnologías usadas

AGENTE

LangChain
LangGraph

MODELOS LOCALES

Ollama con qwen2.5:7b, bge-m3 y qwen2.5vl:3b
faster-whisper para audio y video

DATOS

PostgreSQL 17 con pgvector

BACKEND

Python 3.12
FastAPI
uv

SEGURIDAD

Keycloak 26
JWT RS256 con PKCE

FRONTEND

React 19
Vite

INFRAESTRUCTURA

Docker Compose

Agente con LangChain y LangGraph

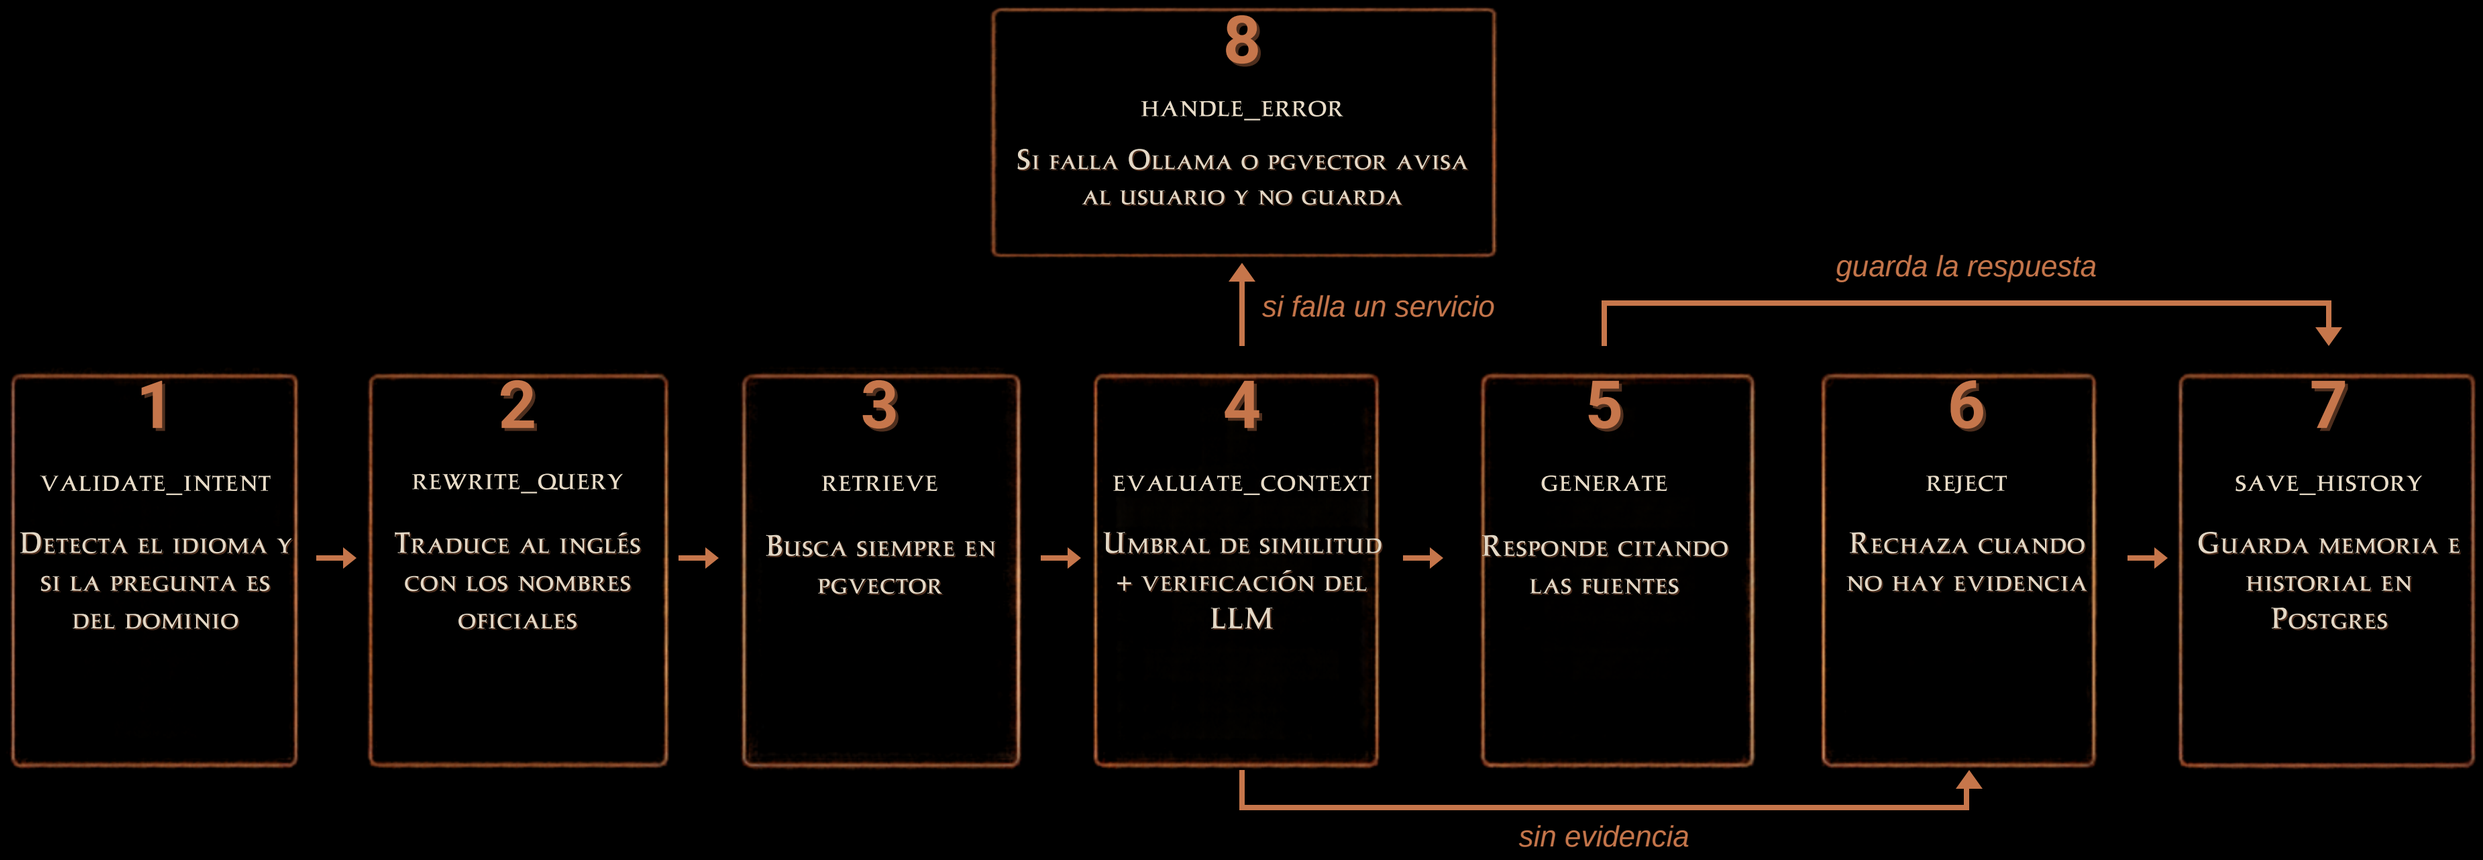

Control de Alucinaciones

Seis estrategias para respuestas confiables

1	Búsqueda obligatoria antes de responder
2	Umbral de similitud
3	Nodo dedicado que valida si el contexto responde la pregunta
4	Prompt restrictivo
5	Rechazo explícito: No tengo suficiente información en mi base de conocimiento para responder esa pregunta
6	Fuentes visibles: cada dato cita el archivo del que salió

Base Vectorial y Carga de Documentos

1 — Cargar
Subida desde la web disponible al instante para el agente

2 — Metadatos
Título (juego) > Sección

3 — Fragmentar
Fragmentos de 1000 caracteres

4 — Embeber
bge-m3: se pregunta en español sobre una wiki en inglés

5 — Guardar
Base vectorial lista para recuperación y respuestas

401 páginas de la wiki

5 imágenes y un video de casi 3 horas

Formatos
PDF, TXT, MD, DOCX, CSV, JPG, PNG, MP3, MP4

Multimedia
Imágenes: el modelo de visión lee o describe

Video: Whisper en bloques citables de 90 s

Base inicial
Contenido diverso listo para buscar, citar y conversar

Seguridad y Usuarios

Autenticación con **Keycloak**
registro, login y cierre de sesión

Tokens validados por el backend
firma **RS256**, expiración, emisor y cliente

Los **11 endpoints** exigen token
sin él responden **401**

Datos y sesiones **aislados** por usuario
historial, conversaciones y documentos propios
fuentes desactivadas solo para sí

Conclusiones

Un grafo explícito da **control total**:
el modelo no puede saltarse la búsqueda

Calibrar el **umbral** con preguntas reales
fue necesario para equilibrar respuestas y
rechazos

El clasificador pasó a decidir **cómo buscar**, no
si buscar